

期末大作业说明（大数据系统综合实验2025）

一、实验概述

从科大的网站爬取文件数据，存在分布式数据库（HBase）中，做一个搜索引擎，实现校内文件搜索的目的。

二、实验要求

1. 尽可能多的爬取科大的网站，要求包含各学院官网以及各管理部门官网，文档最后列举了一部分网站。
2. 爬取内容最低要求：若网站包含“下载中心”此类文件专栏，则需包含，例如中科大财务处。
3. 搜索引擎需实现的基本结果是：根据搜索内容召回文档（独立的文件）或文本信息，召回结果应按照相关性和契合度排序。
4. 请尽可能多的使用本课程中学到的技术。

三、实验形式

1. 组队情况

本作业可以由1-3人组队完成，按照之前问卷中各同学提交的组队名单完成，未及时提交的同学默认单人完成。如有特殊情况请与助教联系。

2. 实验说明

项目的实验环境在本地进行搭建。（由于开源软件的不同版本搭配，可能会存在各种各样的 bug，请同学们参考平时实验的实验平台）

3. 验收说明

1. **验收需求**：课程设计汇报+课程实验报告提交（附源码）
2. **课程设计汇报时间**：分两次课汇报（暂定12.25开始，后续可能根据进度调整），汇报形式和材料可自行决定，可以用实验报告.pdf 或额外制作 PPT或视频等。
3. **实验报告提交截止时间**：汇报结束一周内，将实验报告提交至助教邮箱：`lvhang1001@mail.ustc.edu.cn`。

4. **实验报告命名格式**：学号_姓名_exp.zip（多人组队只需要写队长的学号姓名即可）

如：PB21000001_张三_exp.zip。如有其他特殊情况请在邮件正文中说明。

4. 实验报告内容

实验报告形式自由，但至少需要包含的信息有：

1. 小组成员名单和具体分工
2. 技术路线（介绍一下该项目用到的主要技术并做简要介绍，尤其是与本课程相关的技术）
3. 实现功能介绍和相应的效果展示
4. 核心代码块（可截图放上去）
5. 该组所有同学各自的总结与心得（如踩坑、错误总结、实验收获等）

参考网站

- 人工智能与数据科学学院 <https://sais.ustc.edu.cn/main.htm>
- 中科大本科生招生网 <https://zsb.ustc.edu.cn/main.htm>
- 中科大就业信息网 <https://www.job.ustc.edu.cn/>
- 中科大教务处 <https://www.teach.ustc.edu.cn/>
- 中科大财务处 <https://finance.ustc.edu.cn/main.htm>
- 中科大学工在线 <https://stuhome.ustc.edu.cn/main.htm>
- 中科大研究生招生在线 <https://yz.ustc.edu.cn/>
- 中科大保卫与校园管理处 <https://bwc.ustc.edu.cn/main.htm>
- 中科大出版社 <https://press.ustc.edu.cn/main.htm>
- 中科大信息科学实验中心 https://ispc.ustc.edu.cn/_web/main.psp
- 中科大科技成果转化处 <https://zhb.ustc.edu.cn/main.htm>
- 中科大校团委青春科大 <https://young.ustc.edu.cn/xtwryxx/list.htm>
- 中科大国合部 <https://vista.ustc.edu.cn/>
- 中科大网络信息中心 <https://ustcnet.ustc.edu.cn/33490/list.htm>
- 中科大资产与后勤保障处 <https://zhc.ustc.edu.cn/main.htm>
- 中科大计算机科学与技术学院 <https://cs.ustc.edu.cn/main.htm>
- 中科大网络空间安全学院 <https://cybersec.ustc.edu.cn/main.htm>
- 中科大少年班学院 <https://sgy.ustc.edu.cn/main.htm>
- 中科大数学科学学院 <https://math.ustc.edu.cn/main.htm>
- 中科大信息科学技术学院 <https://sist.ustc.edu.cn/main.htm>
- 中科大苏州高等研究院 <https://sz.ustc.edu.cn/index.html>
- 中科大软件学院 <https://sse.ustc.edu.cn/?pageid=210/main.htm>

- 中科大先进技术研究院 <https://iat.ustc.edu.cn/iat/index.html>
- (可行选择)